

# ACH0021 – Tratamento e Análise de Dados/Informações (1/2012)

Primeira Prova – Abril/2012

Nome: \_\_\_\_\_ Nº USP: \_\_\_\_\_

Turma/Horário: \_\_\_\_\_ Curso: \_\_\_\_\_

**Observação 1:** Duração da prova: **90 (noventa)** minutos.

**Observação 2:** O uso de calculadora é opcional, e seu empréstimo durante a prova é proibido.

**Formulário** (conjunto de  $n$  elementos  $\{w_i\}$ )

$$\text{Média: } \bar{w} = \frac{1}{n} \sum_{k=1}^n w_k$$

$$\text{Variância: } \sigma^2 = \frac{1}{n} \sum_{k=1}^n (w_k - \bar{w})^2$$

$$\text{Desvio padrão: } \sigma$$

1) Um estudante resolveu medir o tempo que ele necessita para chegar à EACH a partir de seu lar, registrando o tempo de percurso por 80 dias. Os dados de sua pesquisa estão organizados na tabela abaixo.

Tempo de percurso (minutos)	Frequência absoluta
$10q \vdash 14q$	10
$14q \vdash 16q$	26
$16q \vdash 18q$	20
$18q \vdash 22q$	24
TOTAL	80

a) [2,0 pontos] Estimar a média  $\bar{t}$  do tempo de percurso e o desvio padrão  $\sigma$ .

A fim de decidir se um dado é típico dentre os registrados, adotou-se o seguinte critério: “Um dado será considerado típico se estiver até a uma distância de  $m\sigma$  da média  $\bar{t}$ , onde  $m \in \mathbb{R}$ .”

b) [1,5 pontos] No octogésimo primeiro dia (que não está contemplado na tabela), o aluno gastou  $17,5q$  minutos para chegar à EACH. Estimar  $m$  de sorte que este dia não seja um dado típico quando comparado com os oitenta já registrados (que estão na tabela acima).

Prova A:  $q = 1$

Prova B:  $q = 2$

Prova C:  $q = 3$

Prova D:  $q = 4$

2a) Assumindo uma distribuição uniforme dos dados em cada intervalo da variável e tomando o ponto médio  $t_i$  de cada um destes como sendo o respectivo representante, tem-se

Tempo de percurso (min)	$t_i$ (min)	Frequência absoluta ( $n_i$ )	Frequência relativa ( $f_i$ )	Amplitude ( $\Delta_i$ )	Densidade ( $d_i$ )
$10q \vdash 14q$	$12q$	10	$10/80 = 0,125$	$4q$	$1/(32q)$
$14q \vdash 16q$	$15q$	26	$26/80 = 0,325$	$2q$	$13/(80q)$
$16q \vdash 18q$	$17q$	20	$20/80 = 0,250$	$2q$	$1/(8q)$
$18q \vdash 22q$	$20q$	24	$24/80 = 0,300$	$4q$	$3/(40q)$
TOTAL	-	80	1,000	-	-

Estimativa da média dos  $n = 80$  dados:

$$\bar{t} = \frac{1}{n} \sum_i n_i t_i = \frac{1}{80} [10 \cdot 12q + 26 \cdot 15q + 20 \cdot 17q + 24 \cdot 20q] = \frac{133q}{8} = 16,625q \text{ (min)}.$$

Estimativa da variância:

$$\begin{aligned} \sigma^2 &= \frac{1}{n} \sum_i n_i (t_i - \bar{t})^2 = \frac{1}{80} \left[ 10(12q - 16,625q)^2 + 26(15q - 16,625q)^2 + \right. \\ &\quad \left. + 20(17q - 16,625q)^2 + 24(20q - 16,625q)^2 \right] = \frac{447q^2}{64}, \end{aligned}$$

que implica um desvio padrão de  $\sigma = \sqrt{\frac{447}{64}}q$  (min). Em suma, tem-se

$$\left\{ \begin{array}{ll} \text{Prova A } (q = 1): & \text{Estimativas: } \bar{t} = 16,625 \text{ (minutos) e } \sigma \approx 2,643 \text{ (minutos)} \\ \text{Prova B } (q = 2): & \text{Estimativas: } \bar{t} = 33,250 \text{ (minutos) e } \sigma \approx 5,286 \text{ (minutos)} \\ \text{Prova C } (q = 3): & \text{Estimativas: } \bar{t} = 49,875 \text{ (minutos) e } \sigma \approx 7,928 \text{ (minutos)} \\ \text{Prova D } (q = 4): & \text{Estimativas: } \bar{t} = 66,500 \text{ (minutos) e } \sigma \approx 10,571 \text{ (minutos)} \end{array} \right.$$


2b) Seguindo o critério de tipicidade, para que o octogésimo primeiro tempo não seja típico, é necessário e suficiente que esse não pertença ao intervalo  $(\bar{t} - m\sigma, \bar{t} + m\sigma)$ , tomando  $m \geq 0$ . Como o tempo de  $17,5q$  minutos é superior à média  $\bar{t}$ , é suficiente analisar a situação  $\bar{t} + m\sigma < 17,5q$ , que implica

$$(0 \leq) m < \frac{17,5q - \bar{t}}{\sigma} = \frac{17,5q - 16,625q}{\sqrt{\frac{447}{64}}q} = \frac{7}{\sqrt{447}} \approx 0,331.$$

Logo, se  $m \in [0, \frac{7}{\sqrt{447}}) \approx [0; 0,331)$ , o tempo de  $17,5q$  é excluído do intervalo  $(\bar{t} - m\sigma, \bar{t} + m\sigma)$ .

**Nota:** Reparar que  $m$  independe do valor de  $q$ , sendo o mesmo para as quatro provas.

2) Para fazer o papel de herói em uma peça de teatro,  $N$  atores enviaram seus currículos ao diretor, e o histograma referente à altura deles é exibido abaixo.



a) [2,0 pontos] Para contracenar de forma satisfatória com a atriz principal, o diretor julgou que os atores deveriam ter uma altura entre  $a$  cm e  $b$  cm. Estimar o número de candidatos situados nessa faixa.

b) [2,0 pontos] Nesta mesma peça, há um papel secundário de “árvore”, que seria melhor desempenhado por atores com uma dada altura mínima. A fim de selecionar os candidatos que satisfaçam esta condição, o diretor requisitou separar  $p$  dos candidatos mais altos. Estimar a altura mínima  $m$  destes atores – isto é, determinar a altura  $m$  acima da qual encontram-se exatamente  $p$  de todos os candidatos.

Prova A:	$N = 330$	$a = 168$	$b = 183$	$p = 12\%$
Prova B:	$N = 270$	$a = 171$	$b = 186$	$p = 14\%$
Prova C:	$N = 180$	$a = 174$	$b = 189$	$p = 16\%$
Prova D:	$N = 120$	$a = 177$	$b = 192$	$p = 18\%$

2a) Tabela de frequência a partir do histograma:

Altura (cm)	Densidade	Amplitude (cm)	Frequência Relativa	Frequência Absoluta
155 ┊ 165	0,015	10	$0,015 \cdot 10 = 0,15 = 15\%$	$0,15N$
165 ┊ 180	0,030	15	$0,030 \cdot 15 = 0,45 = 45\%$	$0,45N$
180 ┊ 195	0,020	15	$0,020 \cdot 15 = 0,30 = 30\%$	$0,30N$
195 ┊ 205	0,010	10	$0,010 \cdot 10 = 0,10 = 10\%$	$0,10N$
TOTAL	-	-	$1,00 = 100\%$	$N$

Assumindo uma distribuição uniforme dos dados nas barras do histograma, e notando que  $a \in [165, 180)$  (em cm) e  $b \in [180, 195)$  (em cm), tem-se

$$d_{165 \vdash 180} = d_{a \vdash 180} \Rightarrow 0,030 = \frac{f_{a \vdash 180}}{180 - a} \Rightarrow f_{a \vdash 180} = \frac{3}{100}(180 - a)$$

e

$$d_{180 \vdash 195} = d_{180 \vdash b} \Rightarrow 0,020 = \frac{f_{180 \vdash b}}{b - 180} \Rightarrow f_{180 \vdash b} = \frac{1}{50}(b - 180).$$

A fração de atores situadas na faixa estabelecida é, pois,

$$f_{a \vdash b} = f_{a \vdash 180} + f_{180 \vdash b} = \frac{3}{100}(180 - a) + \frac{1}{50}(b - 180) = \frac{180 - 3a + 2b}{100},$$

ou

$$\left\{ \begin{array}{l} \text{Prova A: } f_{168 \vdash 183} = 0,42 = 42\% \Rightarrow 0,42 \cdot 330 = 138,6 \approx 139 \text{ (atores)} \\ \text{Prova B: } f_{171 \vdash 186} = 0,39 = 39\% \Rightarrow 0,39 \cdot 270 = 105,3 \approx 105 \text{ (atores)} \\ \text{Prova C: } f_{174 \vdash 189} = 0,36 = 36\% \Rightarrow 0,36 \cdot 180 = 64,8 \approx 65 \text{ (atores)} \\ \text{Prova D: } f_{177 \vdash 192} = 0,33 = 33\% \Rightarrow 0,33 \cdot 120 = 39,6 \approx 40 \text{ (atores)} \end{array} \right. .$$

2b) Sendo  $f_{195 \vdash 205} = 10\%$  e  $f_{180 \vdash 195} = 30\%$ , nota-se que o ponto  $m$  (altura requisitada) situa-se no intervalo  $180 \vdash 195$  (em cm); ademais, é imediato que  $f_{m \vdash 195} = f_{m \vdash 205} - f_{195 \vdash 205} = p - 0,10$ . Assumindo uma distribuição uniforme dos dados nessa faixa, tem-se

$$d_{180 \vdash 195} = d_{m \vdash 195} \Rightarrow 0,020 = \frac{\overbrace{f_{m \vdash 195}}^{p-0,10}}{195 - m} \Rightarrow m = 200 - 50p.$$

Logo,

$$\left\{ \begin{array}{l} \text{Prova A } (p = 12\%): \text{ Estimativa da altura mínima requisitada: } 200 - 50 \cdot 0,12 = 194,0 \text{ (cm)} \\ \text{Prova B } (p = 14\%): \text{ Estimativa da altura mínima requisitada: } 200 - 50 \cdot 0,14 = 193,0 \text{ (cm)} \\ \text{Prova C } (p = 16\%): \text{ Estimativa da altura mínima requisitada: } 200 - 50 \cdot 0,16 = 192,0 \text{ (cm)} \\ \text{Prova D } (p = 18\%): \text{ Estimativa da altura mínima requisitada: } 200 - 50 \cdot 0,18 = 191,0 \text{ (cm)} \end{array} \right. .$$

3) O desempenho de um jogador de basquete em cobranças de lances livres foi registrado. De um total de  $n$  lançamentos ( $n > 1$ ), cada acerto foi indicado por 1 ponto e cada erro, por 0 ponto.

[1,5 pontos] a) Determinar o desvio padrão caso o jogador tenha sido bem sucedido em  $1/4$  de suas cobranças (suponha, em caso de desconforto, que  $n$  seja múltiplo de 4).

[1,0 ponto] b) Determinar o desvio padrão máximo.

3a) Seja  $n_1$  o número de acertos (e, por conseguinte, o número de erros é  $n_0 = n - n_1$ ). A média de pontos  $\bar{x}$  é dada por

$$\bar{x} = \frac{1}{n} [n_0 \cdot 0 + n_1 \cdot 1] = \frac{n_1}{n},$$

que implica uma variância  $\sigma^2$  de

$$\begin{aligned} \sigma^2 &= \frac{1}{n} [n_0 (0 - \bar{x})^2 + n_1 (1 - \bar{x})^2] = \frac{1}{n} \left[ \overbrace{(n - n_1)}^{n_0} \left(0 - \frac{n_1}{n}\right)^2 + n_1 \left(1 - \frac{n_1}{n}\right)^2 \right] \\ &= \frac{n_1}{n} \left(1 - \frac{n_1}{n}\right), \end{aligned} \quad (1)$$

donde se chega ao desvio padrão

$$\sigma = \sqrt{\frac{n_1}{n} \left(1 - \frac{n_1}{n}\right)}. \quad (2)$$

Caso o jogador acerte  $1/4$  de suas cobranças ( $n_1 = n/4$ ), tem-se

$$\sigma = \sqrt{\frac{n/4}{n} \left(1 - \frac{n/4}{n}\right)} = \frac{\sqrt{3}}{4}, \quad (3)$$

conforme requisitado.

3b) Da equação (2), é imediato que o valor máximo do desvio padrão coincide com o valor máximo da função  $f(x) = x(1 - x)$ , onde  $x := n_1/n$  (quando então  $f$  coincide com a variância). Como  $f$  é uma parábola côncava, o ponto máximo realiza-se no ponto médio de suas raízes, que é  $x = 1/2$ . Como  $f(1/2) = 1/4$ , o desvio padrão máximo é  $1/2$ .